

Математика для Machine Learning

Линдеманн Никита

Ноябрь 2018

Содержание

1	Элементы математического анализа	2
1.1	Производная функции одной переменной	2
1.2	Частные производные и градиент	3
2	Основы линейной алгебры	5
2.1	Векторы и матрицы	5
2.2	Сложение и вычитание матриц, умножение матриц на число	5
2.3	Умножение матриц	6
2.4	Транспонирование, скалярное произведение, длина вектора	7
2.5	Ранг и определитель матрицы	9
3	Некоторые понятия теории вероятностей	11
3.1	Классическая вероятность	11
3.2	Случайные величины	11
3.3	Математическое ожидание и дисперсия	12

1 Элементы математического анализа

1.1 Производная функции одной переменной

Определение 1.1.1 Производная функции одной переменной $y = f(x)$ — это предел:

$$\frac{d}{dx}f(x) = \frac{dy}{dx} = f'(x) = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x) - f(x)}{\Delta x}.$$

Пример

Найдем по определению производную функции $y = x^2$ в точке $x_0 = 3$:

$$y'(x) = \lim_{\Delta x \rightarrow 0} \frac{(x + \Delta x)^2 - x^2}{\Delta x} = \lim_{\Delta x \rightarrow 0} \frac{2x\Delta x + \Delta x^2}{\Delta x} = \lim_{\Delta x \rightarrow 0} (2x + \Delta x) = 2x.$$

Далее подставим значение $x_0 = 3$ в найденную функцию $y'(x) = 2x$:

$$y'(x_0) = y'(3) = 2 \cdot 3 = 6.$$

Конечно, на практике никто не считает производные по определению, для этого есть готовая таблица производных элементарных функций (которую полезно помнить наизусть) и правила дифференцирования.

Правила дифференцирования:

- 1) Линейность производной: $(\alpha f(x) + \beta g(x))' = \alpha f'(x) + \beta g'(x)$.
- 2) Производная произведения: $(f(x)g(x))' = f'(x)g(x) + f(x)g'(x)$.
- 3) Производная частного:

$$\left(\frac{f(x)}{g(x)} \right)' = \frac{f'(x)g(x) - f(x)g'(x)}{g^2(x)}.$$

- 4) Производная сложной функции:

$$(f(u))' = f'(u) \cdot u'.$$

Пример

Найдем производную функции $y(x) = \frac{\cos(x^2+1)}{\ln(1-2x)+3}$:

$$y'(x) = \frac{(\cos(x^2 + 1))' \cdot (\ln(1 - 2x) + 3) - (\cos(x^2 + 1)) \cdot (\ln(1 - 2x) + 3)'}{(\ln(1 - 2x) + 3)^2}.$$

Отдельно найдем производные:

$$(\cos(x^2 + 1))' = 2x \cdot (-\sin(x^2 + 1)).$$

$$(\ln(1 - 2x) + 3)' = -2 \cdot \frac{1}{1 - 2x}.$$

Окончательно имеем:

$$y'(x) = \frac{-2x \sin(x^2 + 1) \cdot (\ln(1 - 2x) + 3) + (\cos(x^2 + 1)) \cdot \frac{2}{1 - 2x}}{(\ln(1 - 2x) + 3)^2}.$$

Здесь стоит упомянуть про физический и геометрический смысл производной: ее можно интерпретировать как скорость изменения какой-либо величины (например, скорость материальной точки в механике) или как тангенс угла наклона касательной к графику функции. Именно из интерпретации производной как тангенса угла наклона касательной следуют важные прикладные теоремы, ради которых мы и ввели это понятие.

ТЕОРЕМА Функция принимает свое локально максимальное или минимальное (экстремальное) значение только в тех точках, где ее производная равна нулю (обратное не всегда верно):

$$\begin{aligned} y(x_0) \rightarrow \min &\Rightarrow y'(x_0) = 0, \\ y(x_0) \rightarrow \max &\Rightarrow y'(x_0) = 0. \end{aligned}$$

ТЕОРЕМА Функция $y = f(x)$ строго *возрастает* на промежутке (a, b) , тогда и только тогда, когда в каждой точке этого промежутка производная $f'(x)$ строго положительна, или на математическом языке:

$$y = f(x) \nearrow, x \in (a, b) \Leftrightarrow \forall x \in (a, b) \hookrightarrow f'(x) > 0.$$

ТЕОРЕМА Функция $y = f(x)$ строго *убывает* на промежутке (a, b) , тогда и только тогда, когда в каждой точке этого промежутка производная $f'(x)$ строго отрицательна, или на математическом языке:

$$y = f(x) \searrow, x \in (a, b) \Leftrightarrow \forall x \in (a, b) \hookrightarrow f'(x) < 0.$$

1.2 Частные производные и градиент

Определение 1.2.1 Рассмотрим функцию $f(x_1, x_2, \dots, x_n)$ от n переменных $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Частная производная $f(x_1, x_2, \dots, x_n)$ по переменной x_k – это предел:

$$f'_{x_k} = \frac{\partial}{\partial x_k} f(x_1, \dots, x_k, \dots, x_n) = \lim_{\Delta x \rightarrow 0} \frac{f(x_1, \dots, x_k + \Delta x, \dots, x_n) - f(x_1, \dots, x_k, \dots, x_n)}{\Delta x}.$$

Нахождение частных производных почти ничем не отличается от нахождения производной функции одной переменной (а чаще даже бывает и проще) – просто надо найти производную функции $f(x_k)$, считая все остальные переменные $x_1, \dots, x_{k-1}, x_{k+1}, \dots, x_n$ константами.

Пример

Найдем дифференциал функции $f(x, y, z) = x \cos(2y - z) + xy$ по формуле

$$df(x, y, z) = \frac{\partial f}{\partial x} dx + \frac{\partial f}{\partial y} dy + \frac{\partial f}{\partial z} dz.$$

Для этого найдем частные производные:

$$\begin{aligned} \frac{\partial f}{\partial x} &= f'_x = \cos(2y - z) + y, \\ \frac{\partial f}{\partial y} &= f'_y = 2x \cdot (-\sin(2y - z)) + x, \\ \frac{\partial f}{\partial z} &= f'_z = -x \cdot (-\sin(2y - z)). \end{aligned}$$

Окончательно имеем:

$$df(x, y, z) = (\cos(2y - z) + y)dx + (-2x \cdot \sin(2y - z) + x)dy + (x \cdot \sin(2y - z))dz.$$

Определение 1.2.2 *Градиентом* функции $f(x_1, x_2, \dots, x_n)$ от n переменных называется n -мерный вектор, составленный из частных производных функции f :

$$\mathbf{grad} f(x_1, x_2, \dots, x_n) = \begin{pmatrix} f'_{x_1} \\ f'_{x_2} \\ \vdots \\ f'_{x_n} \end{pmatrix}.$$

Смысл градиента таков: это вектор, указывающий в направлении наибольшего возрастания функции $f(x_1, x_2, \dots, x_n)$, значение которой меняется от одной точки пространства к другой, а по величине (модулю) равный скорости роста этой функции в этом направлении.

Пример

Найдем градиент функции $f(x_1, x_2, x_3, x_4) = x_2 \sin(x_1 x_3) + 2x_4$ в точке $(\frac{3\pi}{2}, 0, 1, -2)$.
Частные производные:

$$f'_{x_1} = x_2 x_3 \cos(x_1 x_3),$$

$$f'_{x_2} = \sin(x_1 x_3),$$

$$f'_{x_3} = x_2 x_1 \cos(x_1 x_3),$$

$$f'_{x_4} = 2.$$

Подставляя в частные производные соответствующие значения переменных, находим:

$$\mathbf{grad} f = \begin{pmatrix} 0 \\ -1 \\ 0 \\ 2 \end{pmatrix}.$$

2 Основы линейной алгебры

2.1 Векторы и матрицы

Определение 2.1.1 *Вектор* – это упорядоченный одномерный массив чисел.

Мы будем обозначать векторы строчными латинскими буквами полужирным шрифтом и записывать их в виде вектор-столбца:

$$\mathbf{a} = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{pmatrix}.$$

Определение 2.1.2 *Матрица* – это упорядоченный двумерный массив чисел.

Множество матриц с m строками и n столбцами, то есть матрицы размеров $m \times n$, будем обозначать $\mathbf{M}_{m \times n}$. Произвольную матрицу $A \in \mathbf{M}_{m \times n}$ будем обозначать заглавными латинскими буквами и записывать в следующем виде:

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix},$$

где на пересечении i -той строки с j -тым столбцом будет находиться элемент матрицы a_{ij} . То есть первый индекс элемента матрицы – номер строки, второй – номер столбца, в котором находится элемент.

Заметим, что вектор – частный случай матрицы: действительно, матрица размерами $m \times 1$ – в точности и есть вектор-столбец. Значит, если мы научимся работать с матрицами, то сразу же получим и правила работы с векторами. Поэтому далее пока что не будем отдельно рассматривать векторы, а будем работать с матрицами произвольных размеров $m \times n$, считая, что возможны случаи $n = 1$.

2.2 Сложение и вычитание матриц, умножение матриц на число

Определение 2.2.1 Пусть даны две матрицы $A, B \in \mathbf{M}_{m \times n}$: $A = (a_{ij})$, $B = (b_{ij})$. Матрица $C = (c_{ij})$ называется *суммой матриц* A и B , если $c_{ij} = a_{ij} + b_{ij}$ для любых $i = \overline{1, m}$ и $j = \overline{1, n}$. Будем обозначать $A + B = C$.

Определение 2.2.2 Пусть даны две матрицы $A, B \in \mathbf{M}_{m \times n}$: $A = (a_{ij})$, $B = (b_{ij})$. Матрица $C = (c_{ij})$ называется *разностью матриц* A и B , если $c_{ij} = a_{ij} - b_{ij}$ для любых $i = \overline{1, m}$ и $j = \overline{1, n}$. Будем обозначать $A - B = C$.

Очевидно, что при таком определении мы можем складывать только матрицы одного размера, и это достаточно важное замечание!

Пример

$$\begin{pmatrix} 1 & -4 & 0 \\ 5 & 3 & -1 \end{pmatrix} + \begin{pmatrix} 4 & 5 & -7 \\ 0 & 2 & 1 \end{pmatrix} = \begin{pmatrix} 5 & 1 & -7 \\ 5 & 5 & 0 \end{pmatrix}.$$

Определение 2.2.3 Пусть дана матрица $A \in \mathbf{M}_{m \times n}$: $A = (a_{ij})$ и число λ . Матрица $C = (c_{ij})$ называется *произведением матрицы A на число λ* , если $c_{ij} = \lambda a_{ij}$ для любых $i = \overline{1, m}$ и $j = \overline{1, n}$. Будем обозначать $\lambda A = C$.

Пример:

$$8 \cdot \begin{pmatrix} 1 & 7 \\ 2 & -3 \end{pmatrix} = \begin{pmatrix} 8 & 56 \\ 16 & -24 \end{pmatrix}.$$

Так как мы ввели сложение и вычитание матриц и умножение матриц на число покомпонентно, то все свойства чисел, связанные с этими операциями, остаются верными и для матриц.

2.3 Умножение матриц

Определение 2.3.1 Пусть даны две матрицы $A \in \mathbf{M}_{m \times n}$ и $B \in \mathbf{M}_{n \times p}$: $A = (a_{ij})$, $B = (b_{ij})$. Матрица $C = (c_{ij}) \in \mathbf{M}_{m \times p}$ называется *произведением матриц A и B* , если

$$c_{ij} = \sum_{k=1}^n a_{ik} b_{kj}$$

для любых $i = \overline{1, m}$ и $j = \overline{1, p}$. Будем обозначать $A \cdot B = C$.

Из определения следует, что мы можем перемножать матрицы, только если количество столбцов у первой равно количеству строк у второй. Это важное замечание!

Пример

Найдем $C = AB$, где

$$A = \begin{pmatrix} 0 & -1 \\ 4 & 5 \\ -8 & 6 \end{pmatrix}, B = \begin{pmatrix} 3 & 1 \\ -2 & 0 \end{pmatrix}.$$

1. Найдем размер результирующей матрицы. Для этого запишем размеры перемножаемых матриц, в данном случае это 3×2 и 2×2 . Убеждаемся, что количество столбцов у первой матрицы равно количеству строк у второй, значит, мы можем перемножить матрицы. Размер результирующей матрицы будет равен «количество строк первой матрицы \times количество столбцов второй матрицы», то есть 3×2 .

2. Последовательно найдем элементы результирующей матрицы $C = c_{ij}$. Для этого обозначим матрицы $A = (a_{ij})$, $B = (b_{ij})$:

$$A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{pmatrix}, B = \begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{pmatrix}.$$

Тогда по определению:

$$c_{11} = \sum_{k=1}^2 a_{1k} b_{k1} = a_{11} b_{11} + a_{12} b_{21} = 0 \cdot 3 + (-1) \cdot (-2) = 2,$$

$$c_{21} = \sum_{k=1}^2 a_{2k} b_{k1} = a_{21} b_{11} + a_{22} b_{21} = 0 \cdot 1 + (-1) \cdot 0 = 0,$$

$$c_{21} = \sum_{k=1}^2 a_{2k}b_{k1} = a_{21}b_{11} + a_{22}b_{21} = 4 \cdot 3 + 5 \cdot (-2) = 2,$$

$$c_{22} = \sum_{k=1}^2 a_{2k}b_{k2} = a_{21}b_{12} + a_{22}b_{22} = 4 \cdot 1 + 5 \cdot 0 = 4,$$

$$c_{31} = \sum_{k=1}^2 a_{3k}b_{k1} = a_{31}b_{11} + a_{32}b_{21} = (-8) \cdot 3 + 6 \cdot (-2) = -36,$$

$$c_{32} = \sum_{k=1}^2 a_{3k}b_{k2} = a_{31}b_{12} + a_{32}b_{22} = (-8) \cdot 1 + 6 \cdot 0 = -8.$$

3. Запишем ответ:

$$C = \begin{pmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \\ c_{31} & c_{32} \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 2 & 4 \\ -36 & -8 \end{pmatrix} = 2 \cdot \begin{pmatrix} 1 & 0 \\ 1 & 2 \\ -18 & -4 \end{pmatrix}.$$

Таким образом, можно вывести мнемоническое правило для произведения матриц: чтобы получить элемент c_{ij} результирующей матрицы, умножаем i -ую строку первой матрицы на j -ый столбец второй матрицы «почленно».

Свойства умножения матриц:

- 1) Ассоциативность: $A(BC) = (AB)C$.
- 2) Антикоммутативность: $AB \neq BA$.
- 3) Дистрибутивность: $A(B + C) = AB + AC$, $(A + B)C = AC + BC$.
- 4) Ассоциативность и коммутативность относительно умножения на число: $(\lambda A)B = \lambda(AB) = A(\lambda B)$.

2.4 Транспонирование, скалярное произведение, длина вектора

Определение 2.4.1 Пусть дана матрица $A \in \mathbf{M}_{m \times n}$: $A = (a_{ij})$. Матрица $C = (c_{ij}) \in \mathbf{M}_{n \times m}$ называется *транспонированной* к A , если $c_{ij} = a_{ji}$ для любых $i = \overline{1, n}$ и $j = \overline{1, m}$. Будем обозначать транспонированную к A матрицу как A^T .

Пример

$$\begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}^T = \begin{pmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{pmatrix}.$$

То есть при транспонировании матрицы i -ая строка становится i -ым столбцом, а j -ый столбец становится j -ой строкой.

Свойства транспонирования:

- 1) $(A + B)^T = A^T + B^T$.
- 2) $(A - B)^T = A^T - B^T$.
- 3) $(\lambda A)^T = \lambda A^T$.
- 4) $(AB)^T = B^T A^T$.

Определение 2.4.2 Скалярное произведение векторов

$$\mathbf{a} = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{pmatrix}, \mathbf{b} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{pmatrix}$$

это

$$\langle \mathbf{a}, \mathbf{b} \rangle = \mathbf{a}^T \cdot \mathbf{b} = \begin{pmatrix} a_1 & a_2 & \dots & a_n \end{pmatrix} \cdot \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{pmatrix} = \sum_{k=1}^m a_k b_k.$$

Пример

Найдем скалярное произведение векторов $\mathbf{a}^T = (-2 \ 6 \ 0 \ 5)$ и $\mathbf{b}^T = (4 \ 3 \ 8 \ -2)$:
По определению имеем:

$$\langle \mathbf{a}, \mathbf{b} \rangle = \sum_{k=1}^4 a_k b_k = (-2) \cdot 4 + 6 \cdot 3 + 0 \cdot 8 + 5 \cdot (-2) = 0.$$

Мы получили, что векторы \mathbf{a} и \mathbf{b} ортогональны.

Определение 2.4.3 Два ненулевых вектора называются *ортогональными*, если их скалярное произведение равно нулю.

Определение 2.4.4 Длина (модуль) вектора $\mathbf{a}^T = (a_1 \ a_2 \ \dots \ a_m)$ – квадратный корень из скалярного произведения этого вектора на себя, то есть:

$$a = |\mathbf{a}| = \sqrt{\sum_{k=1}^m (a_k)^2}.$$

Пример

Найдем длину вектора $\mathbf{a}^T = (-2 \ 6 \ 0 \ 5)$. По определению:

$$a = |\mathbf{a}| = \sqrt{\sum_{k=1}^4 (a_k)^2} = \sqrt{(-2)^2 + 6^2 + 0^2 + 5^2} = \sqrt{65}.$$

Определение 2.4.5 Скалярное произведение векторов \mathbf{a} и \mathbf{b} – это произведение модулей (длин) этих векторов на косинус угла α между ними:

$$\langle \mathbf{a}, \mathbf{b} \rangle = ab \cdot \cos(\alpha).$$

Мы привели два определения скалярного произведения векторов, что может вызывать некоторую путаницу – ведь определения очень разные. На самом деле эти определения эквивалентны (результат не будет зависеть от способа вычисления), просто определение (2.4.5) более общее, а (2.4.2) более удобно при практическом вычислении.

2.5 Ранг и определитель матрицы

Определение 2.5.1 Система столбцов A_1, A_2, \dots, A_n из $M_{m \times 1}$ называется *линейно зависимой*, если некоторая их нетривиальная линейная комбинация равна нулевому столбцу, то есть если существуют числа $\lambda_1, \lambda_2, \dots, \lambda_n$ такие, что хотя бы одно из этих чисел не нулевое (нетривиальность) и выполнено:

$$\sum_{k=1}^n A_k \lambda_k = O = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}.$$

Пример

Докажем, что следующие столбцы линейно зависимы:

$$\begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} -4 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} -1 \\ 7 \\ 9 \end{pmatrix}.$$

Действительно, существует нетривиальная линейная комбинация этих столбцов, равная нулевому вектору (напомним, что мы отождествляем понятие матрицы размера $m \times 1$ с вектором):

$$3 \cdot \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} + \begin{pmatrix} -4 \\ 1 \\ 0 \end{pmatrix} - \begin{pmatrix} -1 \\ 7 \\ 9 \end{pmatrix} = O.$$

Определение 2.5.2 Целое неотрицательное число r называется *рангом матрицы* A и обозначается $r = \text{rg } A$, если из столбцов этой матрицы можно выбрать r линейно независимых столбцов, но нельзя выбрать $r + 1$ линейно независимых столбцов.

Свойства ранга:

- 1) $\text{rg } A^T = \text{rg } A$.
- 2) Если A – квадратная матрица и $|A| = 0$, то строки и столбцы матрицы линейно зависимы.
- 3) Линейная (не)зависимость столбцов матрицы эквивалентна линейной (не)зависимости строк.
- 4) Если все элементы строки или столбца матрицы умножить на отличное от нуля число, то ранг матрицы не изменится.
- 5) Ранг не изменится, если к элементам любой строки или столбца матрицы прибавить соответствующие элементы другой строки или столбца, умноженные на одно и то же число.
- 6) Ранг не изменится, если переставить два любых столбца или две строки матрицы.

Определение 2.5.3 *Определитель (или детерминант)* матрицы размера 2×2 – это

$$|A| = \det A = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21}.$$

Детерминант матрицы размера 3×3 – это

$$|A| = \det A = \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11} \begin{vmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{vmatrix} - a_{12} \begin{vmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{vmatrix} + a_{13} \begin{vmatrix} a_{21} & a_{22} \\ a_{31} & a_{32} \end{vmatrix}.$$

Заметим, что детерминант определен только для квадратных матриц, то есть только для матриц размеров $n \times n$!

Пример

Найдем определитель:

$$|A| = \det A = \begin{vmatrix} 0 & 1 & 3 \\ 2 & 3 & 5 \\ 3 & 5 & 7 \end{vmatrix} = 0 \cdot \begin{vmatrix} 3 & 5 \\ 5 & 7 \end{vmatrix} - 1 \cdot \begin{vmatrix} 2 & 5 \\ 3 & 7 \end{vmatrix} + 3 \cdot \begin{vmatrix} 2 & 3 \\ 3 & 5 \end{vmatrix} = 0 - (14 - 15) + 3 \cdot (10 - 9) = 4.$$

Мы получили, что наша матрица не вырождена.

Определение 2.5.4 Матрица называется *вырожденной*, если ее определитель равен нулю.

Свойства детерминанта:

- 1) $|A^T| = |A|$.
- 2) $|AB| = |A| \cdot |B|$.
- 3) Умножение всех элементов строки или столбца определителя на некоторое число равносильно умножению определителя на это число.
- 4) Если матрица содержит нулевую строку или столбец, то определитель этой матрицы равен нулю.
- 5) Если две строки или два столбца матрицы линейно зависимы, то определитель этой матрицы равен нулю.
- 6) При перестановке двух любых строк или столбцов определитель матрицы меняет знак.
- 7) Определитель не изменится, если к элементам любой строки или столбца матрицы прибавить соответствующие элементы другой строки или столбца, умноженные на одно и то же число.
- 8) Определитель матрицы треугольного вида равен произведению элементов, стоящих на главной диагонали:

$$|A| = \begin{vmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ 0 & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & a_{nn} \end{vmatrix} = \prod_{k=1}^n a_{kk} = a_{11} \cdot a_{22} \cdot \dots \cdot a_{nn}.$$

Заметим, что последнее свойство позволяет легко находить определитель матриц большого порядка, если перед этим привести матрицу к диагональному виду (что всегда можно сделать, опираясь на предпоследнее свойство и используя алгоритм Гаусса).

3 Некоторые понятия теории вероятностей

3.1 Классическая вероятность

Определение 3.1.1 *Дискретное вероятностное пространство* – это любой конечный набор элементов (*элементарных исходов*) $\Omega = \{\omega_1, \omega_2, \dots, \omega_N\}$, каждому из которых сопоставлено некоторое положительное число $\omega_k \mapsto P_k$ ($k = \overline{1, N}$), причем для этих чисел выполнено условие нормировки:

$$\sum_{k=1}^N P_k = 1.$$

Определение 3.1.2 Число, сопоставленное элементарному исходу ω_i , будем называть *вероятностью* этого исхода и считать, что эта вероятность определена как предел отношения:

$$P_i = \lim_{N \rightarrow \infty} \frac{N(\omega_i)}{N},$$

где $N(\omega_i)$ – это количество испытаний, при котором исход ω_i наступил, а N – общее число испытаний.

Определение 3.1.3 *Событие* – это любое подмножество A множества элементарных исходов Ω : $A \subseteq \Omega$.

Определение 3.1.4 *Вероятность события* A – это сумма вероятностей тех элементарных исходов, которые составляют событие A :

$$P(A) = \sum_{i: \omega_i \in A} P_i.$$

Пример

Рассмотрим опыт с бросанием игральной кости. В нашей терминологии:

1) Вероятностное пространство – это множество всевозможных элементарных исходов: $\Omega = \{\omega_i \mid \omega_i = \{\text{выпала } i\text{-ая грань}\}, i = \overline{1, 6}\}$.

2) Так как в данном эксперименте естественно предположить, что выпадение любой грани равновероятно, то с учетом условия нормировки получается, что i -ая грань выпадет с вероятностью:

$$P_i = \frac{1}{6}.$$

3) Пример события – выпала четная грань. Действительно, выпадение четной грани есть подмножество $A = \{\omega_2, \omega_4, \omega_6\}$ всех элементарных исходов Ω . Тогда вероятность такого события – сумма:

$$P(A) = \sum_{i: \omega_i \in A} P_i = \sum_{i=1}^3 P_i = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{1}{2}.$$

3.2 Случайные величины

Определение 3.2.1 *Случайная величина* ξ – это любая функция, сопоставляющая элементарному исходу из множества Ω некоторое вещественное число, то есть:

$$\xi : \Omega \longrightarrow \mathbb{R}.$$

Очевидно, что по определению функции, случайная величина может принимать только одно из значений $\xi \in \{x_1, x_2, \dots, x_m\}$, где $m \leq N(\Omega)$ (условимся для удобства записывать значения случайной величины в порядке возрастания: $x_i < x_{i+1}$).

Определение 3.2.2 Вероятность того, что ξ принимает некоторое значение x_k равна сумме вероятностей событий ω_i для которых $\xi(\omega_i) = x_k$ или

$$P_\xi(k) = \sum_{i: \xi(\omega_i) = x_k} P_i,$$

где за $P_\xi(k)$ обозначена величина $P(\xi = x_k)$.

Таким образом, случайную величину удобно интерпретировать как результат какого-либо случайного события, то есть $\omega_i \rightarrow \xi(\omega_i)$.

Обратим внимание на то, что под ξ в зависимости от контекста мы можем понимать немного разные вещи. Запись $\xi(\omega_i) = x_j$ означает, что случайная величина ξ ставит в соответствие элементарному исходу ω_i вещественное число x_j , и здесь ξ – функция. Так же под ξ мы можем понимать само значение, которое ставится в соответствие какому-то элементарному исходу.

Пример

Рассмотрим опыт с бросанием уже двух разных игральных костей (что на самом деле эквивалентно двум последовательным бросанием одной игральной кости). Пусть случайная величина – это сумма очков, выпавшая на костях. Тогда очевидно, что $\xi \in \{2, 3, \dots, 12\}$.

Найдем вероятность того, что $\xi = 7$: это реализуется при элементарных исходах $(1, 6)$, $(2, 5)$, $(3, 4)$, $(4, 3)$, $(5, 2)$, $(6, 1)$, где на первом месте записано количество очков, выпавших на первой кости, а на втором – количество очков, выпавших на второй кости. Вероятность любого исхода (i, j) равна $1/36$ при $i, j = \overline{1, 6}$. Тогда по определению:

$$P(\xi) = P(7) = 6 \cdot \frac{1}{36} = \frac{1}{6}.$$

3.3 Математическое ожидание и дисперсия

Определение 3.3.1 Математическое ожидание случайной величины – это сумма произведений вероятности того, что случайная величина принимает некоторое значение, на это значение:

$$E(\xi) = \sum_{i=1}^{N(\Omega)} P_i \xi(\omega_i)$$

По сути матожидание – это некое среднее значение случайной величины при достаточно большом количестве испытаний.

Свойства математического ожидания:

- 1) $E(c\xi) = cE(\xi)$.
- 2) $E(\xi + \eta) = E(\xi) + E(\eta)$.
- 3) $\xi \geq 0 \Rightarrow E(\xi) \geq 0$.
- 4) $\forall i, j \hookrightarrow \xi_i \geq \eta_j \Rightarrow E(\xi) \geq E(\eta)$.

Пример

Рассмотрим следующую игру. В коробке лежит 10 фишек: 5 штук со значением -5, 4 штуки со значением 2,5 и 1 фишка со значением 10. Предлагается вытащить одну из фишек и, если на фишке написано положительное число, то ваш выигрыш – очки на фишке, умноженные на 10, но если вы вытащили фишку с отрицательным значением – вы должны отдать 50 рублей.

Посчитаем матожидание выигрыша. Для этого составим закон распределения случайной величины ξ – выигрыша:

ξ_i	-5	2,5	10
$P(\xi_i)$	0,5	0,4	0,1

По определению математического ожидания:

$$E(\xi) = \sum_{i=1}^{N(\Omega)} P(\xi_i) \xi_i = \sum_{i=1}^3 P(\xi_i) \xi_i = 0,5 \cdot 5 + 0,4 \cdot 2,5 + 0,1 \cdot 10 = -0,5.$$

Таким образом, математическое ожидание данной игры проигрышно, то есть, сыграв много раз в эту игру, вы уйдете, оказавшись в минусе в среднем на 5 рублей.

Определение 3.3.2 *Дисперсией* случайной величины называется величина

$$D(\xi) = E((\xi - E(\xi))^2).$$

Дисперсия позволяет количественно оценить, насколько сильно конкретное значение случайной величины отличается от среднего значения, то есть насколько значения рассеяны, а рассеяние с латыни переводится не иначе, как дисперсия.

Свойства дисперсии:

- 1) $D(\xi) = E(\xi^2) - E(\xi)^2$.
- 2) $D(c\xi) = c^2 D(\xi)$.
- 3) $D(\xi) \geq 0$.
- 4) $D(\xi) = 0 \Leftrightarrow \forall i \hookrightarrow \xi(\omega_i) = E(\xi)$.
- 5) $D(\xi + \eta) \geq D(\xi) + D(\eta)$.

Первое свойство имеет важное прикладное значение. Именно по этой формуле чаще всего и считают дисперсию, так как это проще, чем по определению (в этом мы сможем убедиться на последующем примере).

Определение 3.3.3 *Среднеквадратичное отклонение (стандартное отклонение)* случайной величины – это квадратный корень из дисперсии:

$$\sigma(\xi) = \sqrt{D(\xi)}.$$

Среднеквадратичное отклонение так называется, поскольку характеризует отклонение случайной величины от ее математического ожидания.

Пример

Вернемся к предыдущему примеру. Там мы нашли неутешительное математическое ожидание $E(\xi) = -0,5$ нашей игры, и сейчас нам предстоит вычислить её дисперсию двумя способами: по определению и по первому свойству «дисперсия – это матожидание квадрата минус квадрат матожидания». Для поиска дисперсии первым способом составим таблицу:

ξ_i	-5	2,5	10
$P(\xi_i)$	0,5	0,4	0,1
$\xi_i - E(\xi)$	-4,5	3	10,5
$(\xi_i - E(\xi))^2$	20,25	9	110,25
$(\xi_i - E(\xi))^2 \cdot P(\xi_i)$	10,125	3,6	11,025

Суммируя значения последней строки, получаем дисперсию:

$$D(\xi) = 10,125 + 3,6 + 11,025 = 24,75.$$

Чтобы найти дисперсию по первому свойству, необходимо вычислить величины:

$$E(\xi^2) = \sum_{i=1}^3 P(\xi_i) \xi_i^2 = 0,5 \cdot 25 + 0,4 \cdot 6,25 + 0,1 \cdot 100 = 25.$$

$$E(\xi)^2 = \left(\sum_{i=1}^3 P(\xi_i) \xi_i \right)^2 = (0,5 \cdot (-5) + 0,4 \cdot 2,5 + 0,1 \cdot 10)^2 = (-0,5)^2 = 0,25.$$

Тогда, по формуле $D(\xi) = E(\xi^2) - E(\xi)^2$ получим такой же результат, как и в первом случае:

$$D(\xi) = 25 - 0,25 = 24,75.$$

Из этого примера видно, что последний способ вычисления дисперсии действительно проще, чем подсчет дисперсии по определению.

Размерность дисперсии – рубли в квадрате, поэтому сложно по дисперсии оценить разброс выигрыша или проигрыша в игре. А вот по стандартному отклонению уже становится яснее, насколько сильно разбросаны эти значения относительно вычисленного матожидания:

$$\sigma(\xi) = \sqrt{D(\xi)} = \sqrt{24,75} \approx 5.$$